Big Data

Sujet de Projet de Groupe : **Architecture Big Data : Ingestion, Persistance, Traitement et Insights des Données**

Objectif :

Dans ce projet, chaque groupe doit concevoir une solution d'architecture Big Data pour gérer l'ingestion, la persistance et le traitement d'un jeu de données de leur choix. Ils doivent produire soit un tableau de bord interactif, soit des graphes a travers des agrégations significatives pour visualiser des interrogation **intéressantes** (ou intégrer de l'**intelligence artificielle (IA) et de l'apprentissage automatique (ML)** si souhaité).

Jeux de données proposés :

Chaque groupe peut choisir parmi les jeux de données suivants. Voici une description détaillée de chaque source pour vous aider dans votre choix :

1. **US Government (https://data.gov/)**

   Ce portail offre un accès à une large variété de données gouvernementales américaines, couvrant des domaines tels que l'énergie, la santé, la sécurité publique, et plus encore. Les données sont disponibles en format brut, souvent prêtes à être analysées.

2. **US Census Bureau (https://data.census.gov/cedsci/)**

   Les données du Bureau du recensement des États-Unis fournissent des statistiques sur la population, l'économie et les ménages. Ces données sont idéales pour l'analyse démographique et socio-économique.

3. **Amazon Web Services Open Data (https://registry.opendata.aws/)**

   Ce registre contient des ensembles de données accessibles sur AWS, incluant des informations sur les images satellite, le génome humain, ou encore les données climatiques. Ces ensembles sont souvent volumineux et bien adaptés à des projets nécessitant de grandes capacités de traitement.

4. **Google Trends (https://trends.google.com/trends/explore)**

   Google Trends fournit des données sur les tendances des recherches effectuées à travers le monde. C'est une excellente ressource pour l'analyse des comportements et tendances des utilisateurs.

5. **National Oceanic and Atmospheric Administration (NOAA) (https://www.ncdc.noaa.gov/)**

   La NOAA propose des données météorologiques et climatiques. Ces données peuvent être utilisées pour analyser les changements climatiques, prévoir les conditions météorologiques ou étudier les phénomènes météorologiques extrêmes.

6. **National Centers for Environmental Information (NCEI) (https://www.ncei.noaa.gov/)**

   Le NCEI, qui fait partie de la NOAA, contient l'un des plus grands dépôts de données climatiques et environnementales au monde. Ces ensembles de données incluent des informations historiques sur le climat, les océans et la géophysique.

7. **National Aeronautics and Space Administration (NASA) (https://nasa.github.io/data-nasa-gov-frontpage/)**

   Les ensembles de données de la NASA incluent des informations sur l'exploration spatiale, les missions scientifiques et l'observation de la Terre. Ces données sont idéales pour les projets axés sur les sciences spatiales ou la Terre.

8. **U.S. Geological Survey (USGS) (https://data.usgs.gov/datacatalog/)**

   L'USGS fournit des données sur les sciences de la Terre, notamment sur la sismologie, l'hydrologie et la géographie. Ces données sont précieuses pour les projets liés aux sciences naturelles et à l'environnement.

9. **NASA Infrared Processing and Analysis Center (IRSA) (https://irsa.ipac.caltech.edu/frontpage/)**

   IRSA regroupe des données infrarouges et submillimétriques issues de plusieurs missions de la NASA. Avec ses 88 milliards de lignes de données cataloguées et 100 millions d'images, ces ensembles sont parfaits pour des projets de traitement et d'analyse d'images astronomiques.

10. **NBA Dataset (https://www.kaggle.com/datasets/wyattowalsh/basketball/data)**

    Ce dataset comprend :

    - **30 équipes**, **4800+ joueurs**, **65,000+ matchs** (depuis la saison inaugurale 1946-47).
    - **Scores détaillés** pour plus de 95 % des matchs.
    - **13M+ lignes** de données de Play-by-Play pour l'analyse approfondie des actions en jeu.
      Idéal pour analyser les performances sportives, effectuer des prédictions sur les matchs ou explorer des tendances dans l'histoire de la NBA.

Livrables attendus :

1. **Rapport final :**
    - Présentation succincte du sujet choisi.
    - Description des étapes suivies pour résoudre le problème.
    - Justification des technologies utilisées pour l'ingestion, la persistance et le traitement des données.
    - **Élaboration d'un schéma détaillé de l'architecture Big Data utilisée** (incluant les flux de données et les outils).
    - Diagramme d'activités illustrant le flux de traitement des données.
    - Graphes ou tableaux de bord montrant les résultats obtenus.
    - Intégration possible de techniques d'IA/ML pour enrichir les analyses et faire des prédictions si nécessaire.
    - Réflexion sur les limites et perspectives d'amélioration du projet.
2. **Présentation orale :**
    - Courte présentation (5-10 minutes) sans code, expliquant clairement :
        - Le sujet choisi.
        - La méthodologie.

- Les résultats visuels.
- Les défis rencontrés et les solutions mises en œuvre.
- **L’architecture utilisée, illustrée par un schéma détaillé.**

Technologies suggérées :

Les étudiants sont libres de choisir leurs outils. Cependant, chaque groupe doit clairement justifier les choix de leur stack technologique en fonction de leurs besoins spécifiques.

Bonne chance et bon courage ^^ !